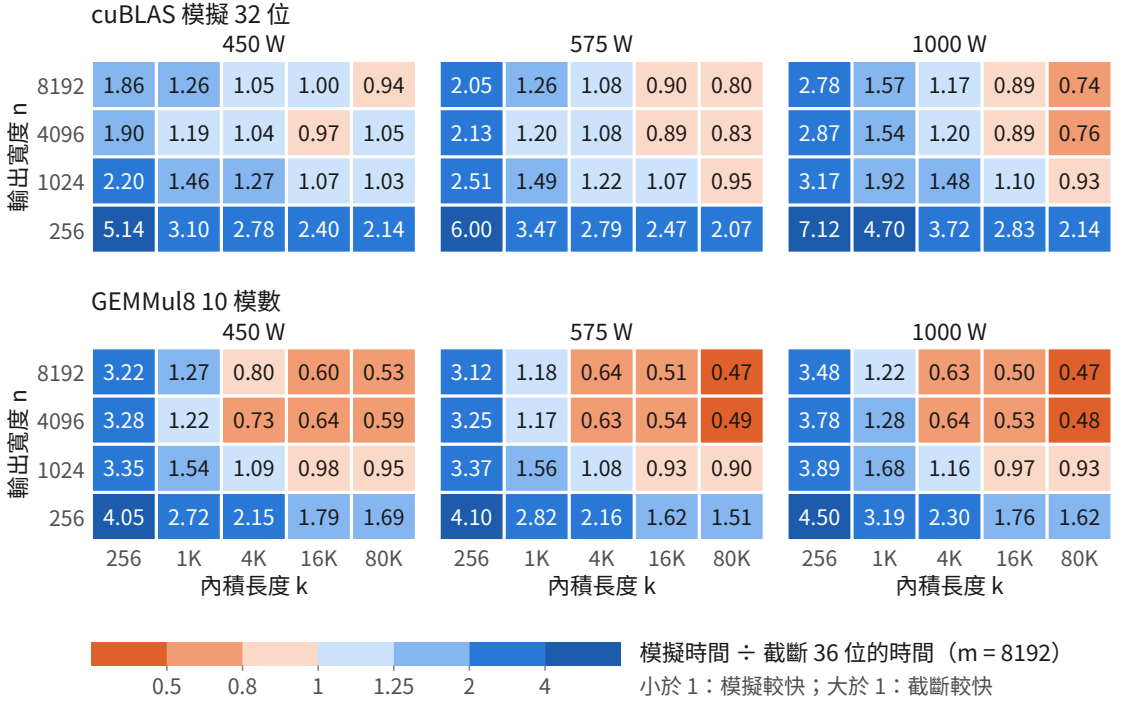
cuBLAS 模擬 32 位
450 W
575 W
1000 W
輸出寬度 n
8192 1.86 1.26 1.05 1.00 0.94 2.05 1.26 1.08 0.90 0.80 2.78 1.57 1.17 0.89 0.74
4096 1.90 1.19 1.04 0.97 1.05 2.13 1.20 1.08 0.89 0.83 2.87 1.54 1.20 0.89 0.76
1024 2.20 1.46 1.27 1.07 1.03 2.51 1.49 1.22 1.07 0.95 3.17 1.92 1.48 1.10 0.93
256 5.14 3.10 2.78 2.40 2.14 6.00 3.47 2.79 2.47 2.07 7.12 4.70 3.72 2.83 2.14
GEMMul8 10 模數
450 W
575 W
1000 W
輸出寬度 n
8192 3.22 1.27 0.80 0.60 0.53 3.12 1.18 0.64 0.51 0.47 3.48 1.22 0.63 0.50 0.47
4096 3.28 1.22 0.73 0.64 0.59 3.25 1.17 0.63 0.54 0.49 3.78 1.28 0.64 0.53 0.48
1024 3.35 1.54 1.09 0.98 0.95 3.37 1.56 1.08 0.93 0.90 3.89 1.68 1.16 0.97 0.93
256 4.05 2.72 2.15 1.79 1.69 4.10 2.82 2.16 1.62 1.51 4.50 3.19 2.30 1.76 1.62
256 1K 4K 16K 80K
內積長度 k
0.5 0.8 1 1.25 2 4
模擬時間 ÷ 截斷 36 位的時間（m = 8192）
小於 1：模擬較快；大於 1：截斷較快