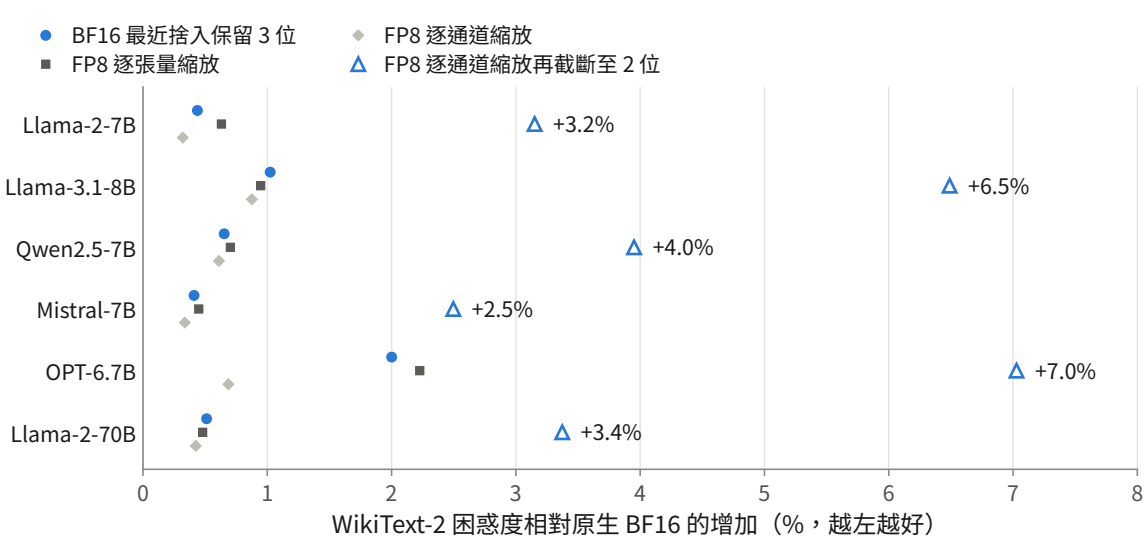
BF16 最近捨入保留 3 位
FP8 逐通道縮放
FP8 逐張量縮放
FP8 逐通道縮放再截斷至 2 位
Llama-2-7B
Llama-3.1-8B
Qwen2.5-7B
Mistral-7B
OPT-6.7B
Llama-2-70B
+3.2%
+6.5%
+4.0%
+2.5%
+7.0%
+3.4%
0
1
2
3
4
5
6
7
8
WikiText-2 困惑度相對原生 BF16 的增加（%，越左越好）